Resumen: El trabajo presentado analiza las diferencias entre productos de edición limitada y los productos regulares disponibles en el dataset de sephora obtenido en Kaggle, con información de un total de 9168 productos. El objetivo es determinar si las ediciones limitadas presentan un mayor nivel de rating y popularidad que los productos tradicionales. Para ello, se realizó una exploración y limpieza de los datos mediante las librerías Pandas, NumPy y Matplotlib de Python.
Luego de eso, se aplicaron agrupaciones y gráficos que representan las comparaciones entre los grupos. Los resultados muestran que los productos regulares presentan una mayor cantidad de favoritos, …… FALTAAAAAAAAAAAAAAAA.

Introducción: Se trabajó con un Dataset de Sephora que cuenta con un total de 9168 diferentes productos de belleza seccionados en 21 columnas que contienen la información completa de cada producto, desde marcas, categorías, detalles, ingredientes, etc. Es un Dataset extraído de la página Kaggle. Lo que más estaremos utilizando es la columna de Ediciones Limitadas, para tratar de hacer una hipótesis y sacar conclusiones sobre la siguiente pregunta:

¿Los productos de Edición Limitada consiguen en general más “Rating” y más “Love” respecto a productos regulares entre los compradores de Sephora, o podemos concluir que quedarse con los productos clásicos es más rentable?

Se consideró esta pregunta relevante para investigar debido a que las ediciones limitadas constituyen una estrategia de marketing habitual basada en la exclusividad y la escasez. La difusión de tendencias en redes sociales actualmente puede generar una sensación de urgencia en consumidores, mayormente entre jóvenes, y aumenta el interés en estos productos.
Gracias a esto, resulta importante estudiar si esta estrategia se refleja efectivamente en una mayor valoración y popularidad dentro de la plataforma. Sephora fue elegida como objeto del análisis por la variedad de reconocidas marcas y productos dentro de sus tiendas físicas y digitales también, lo que permite realizar una comparación justa sobre un conjunto amplio de registros y no limitarse a una sola marca.

Si bien inicialmente se planteó en el grupo la posibilidad de analizar la rentabilidad de ambos tipos de productos, el dataset no contiene información de ganancias, costos, y ventas, por lo tanto, no se pudo evaluar sobre estos datos.

Datos y metodología: Usando el Dataset de Kaggle “Sephora Website”, con link https://www.kaggle.com/datasets/raghadalharbi/all-products-available-on-sephora-website. Las herramientas necesarias que se usaron para el desarrollo fueron Python, librerías (Pandas, Numpy, Google Colab, Matplotlib,
como columnas principales base para el proyecto se usaron:

- *Rating:* Mide la calidad técnica o efectividad real del producto según el comprador.

- *Love Count:* Mide el valor aspiracional, el deseo de compra hacia la marca o productos.
- limited edition: para filtrar los productos que son de edición limitada
- category: para limpiezas de datos

La exploración inicial se realizó con pandas en Google Colab. Primero, se inspeccionaron las primeras y últimas filas del dataset, sus dimensiones y columnas, así identificando los nombres y tipos de datos de las columnas. La base contiene 9168 filas de productos y 21 columnas con sus características. No se detectaron datos nulos mediante isnull().sum() ni filas completamente duplicadas dentro del dataset. Sin embargo, algunas celdas contienen expresiones como “no size”, que indican información no disponible aunque estén registradas como texto y no sean reconocidas como valores nulos por pandas.

Otros datos que se obtuvieron del data set antes de ser aplicadas las transformaciones fue la composición de productos en cuanto a edición. La base cuenta con 842 productos de edición limitada, contra los restantes 8326 productos de edición estándar.

Se calculó la mediana del parámetro ‘love’ haciendo la distinción entre productos estándar y de edición limitada. Esto reflejó una mediana de 5000 en ‘love’ para los productos estándar y una mediana de 3000 para los de edición limitada. Se puede ver que los productos estándar reciben más ‘love’ que los de edición limitada.

Se calculó la media y la mediana del parámetro ‘rating’ diferenciando a los productos por tipo de edición. Tanto las versiones estándar como las limitadas tienen la misma media de rating (4,171) y la misma mediana de rating (4,5).

Como parte de las transformaciones previas al análisis estadístico, para analizar las calificaciones se seleccionaron únicamente los productos con valores de rating mayores a cero. Los registros menores o igual a cero se excluyeron de esta comparación. La base completa se conservó para analizar la cantidad de favoritos (love). Se puede observar en la base de datos que los productos con valoración 0 coinciden con productos sin reviews.

Las estadísticas descriptivas muestran una distribución asimétrica: la media es aproximadamente 16279, la mediana es 4800 y el máximo alcanza 1300000. Por ello, se utilizó la mediana para comparar la popularidad típica de ambos grupos, al ser menos sensibles a valores extremos.

La base no incluye fechas que permitan estudiar su evolución temporal. Tampoco se pudo identificar un mercado geográfico explícito en el dataset consultado, por lo que el alcance del análisis se puede ver limitado a los registros disponibles.

Transformación 3 y 4.

Se creó la variable log_love, aplicando el logaritmo de uno más la cantidad de favoritos (love). Esta transformación facilita visualizar productos con extremos muy diferentes de favoritos, conservando la columna original. Por otro lado, en la 4ta transformación, se creó una variable que identifica los productos con alto rating. Para el análisis se definió como una calificación de 4,5 o más. Esta calificación permite comparar el porcentaje entre los productos limitados y los no limitados.

En el gráfico se combinaron ambas transformaciones en un boxplot agrupado para observar la distribución de favoritos según el tipo de edición y el nivel de rating.

Análisis estadísticas descriptivas

Posterior a las transformaciones se volvieron a calcular media y mediana de los parámetros rating, reviews y love, agrupando los productos según edición. Se puede observar que, incluso luego de la transformación al data set que elimina los productos sin calificación, los productos de edición limitada y los de edición estándar siguen compartiendo el mismo promedio y mediana de rating; sin embargo, los productos de edición estándar registran un volumen significativamente mayor de reviews y 'loves'. Esta mayor tracción y acumulación de interacciones otorga una superior solidez estadística al puntaje del catálogo permanente, actuando como un respaldo que otorga mayor representatividad a su valoración.

Para la segunda medición se creó un dataframe agrupando los productos por categorías y diferenciando también su edición. Dentro de este dataframe se filtraron únicamente las categorías que cuentan con ambas ediciones de sus productos. El propósito de esto es observar si dentro de las categorías de producto se puede distinguir alguna diferencia de performance entre ediciones, lo cual trae las siguientes preguntas: ¿Hay categorías con más ediciones limitadas que otras?; ¿Esta superioridad general en rating de los productos estándar se mantiene si observamos de cerca a cada categoría?

Se puede apreciar que la distribución de ediciones limitadas no es homogénea entre categorías: categorías como Eye Palettes y Lipstick concentran la mayor proporción de lanzamientos temporales, mientras que en Skincare predomina la versión estándar. En cuanto a la superioridad en rating de los productos estándar, podemos ver que no es una constancia dentro de cada categoría. Hay ciertas categorías (por ejemplo perfumes y gift sets) donde las ediciones limitadas logran puntajes parecidos a incluso superiores que los estándar. La ventaja general en rating de los productos estándar no es una regla universal en todo el catálogo, sino un promedio ponderado influenciado por el mayor tamaño muestral de ciertas categorías principales.

Resultados:

(PARTE DE RESULTADOS, NO ESTÁ COMPLETO)
Se comparó la cantidad de favoritos de los productos de edición limitada y los que no son de edición limitada mediante la mediana, que representa el valor central al ordenar los datos.
Los productos de edición limitada presentan una mediana de 3000 favoritos, frente a 5000 en los productos no limitados. Según estos números, la popularidad típica es menor para los productos de edición limitada.

Por otro lado, también se compararon las calificaciones, considerando únicamente los registros con calificaciones mayores que cero. En este subconjunto, ambos grupos presentan una mediana de 4,5. En consecuencia, la comparación de medianas no muestra una mejor valoración de los productos de edición limitada. Esto no significa que todos los productos reciban la misma calificación.

Al comparar el porcentaje de productos con calificaciones mayor o igual a 4,5 se obtuvo un 51,25% para las limited edition y un 50,06% para los productos que no son de limited edition. La diferencia entre estos porcentajes es mínima, de tan solo 1,18 puntos porcentuales. La proporción de alto rating es ligeramente mayor en las limited edition por más que las medianas de calificación sean iguales.

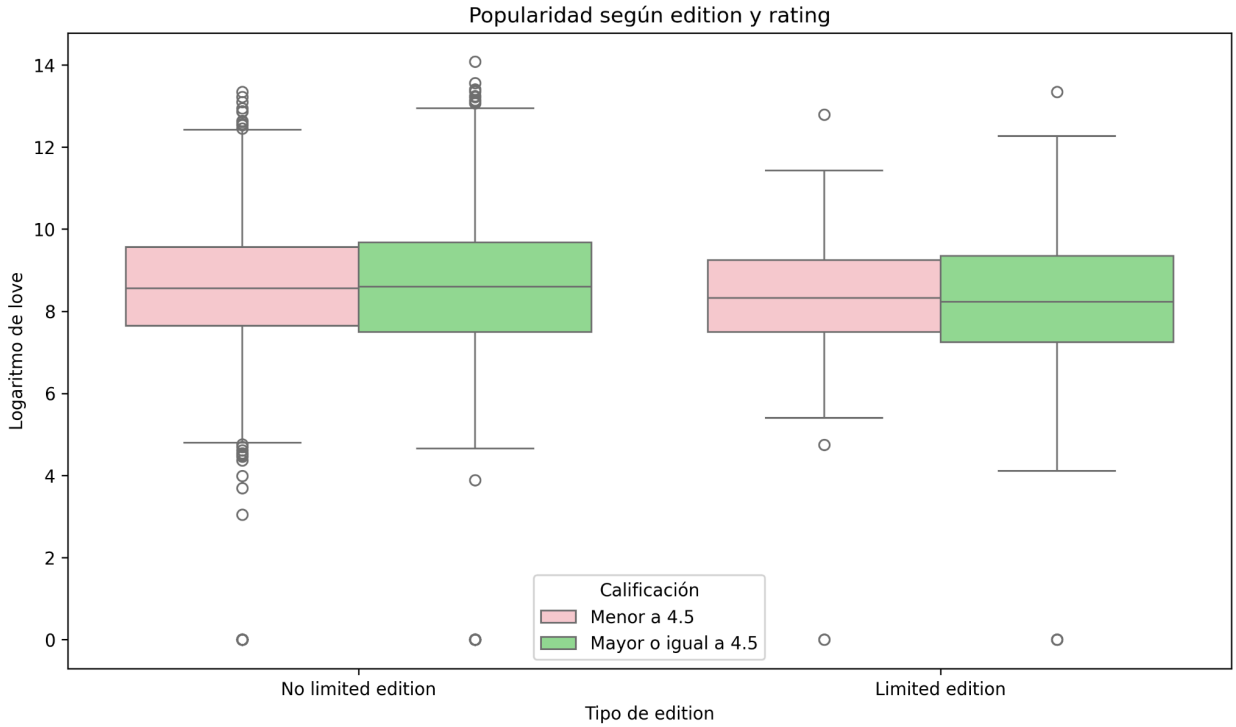


Figura 1. Distribución de favoritos en escala logarítmica según tipo de edición (edition) y valoración (rating).

Los productos no limitados presentan medianas de favoritos más altas en ambos niveles de calificación . Dentro de cada tipo de edición, los productos con calificación de 4,5 o más no muestran una mayor mediana de favoritos. Las distribuciones se superponen considerablemente, por lo que existen productos con niveles similares de popularidad entre cuatro grupos.
Conclusiones:

Según las medianas analizadas, los productos de edición limitada presentan menos favoritos y la misma valoración que los productos que no son de edición limitada.
Sin embargo, las ediciones limitadas presentan una proporción ligeramente mayor de productos con calificaciones de 4,5 o más. Esto muestra que la comparación del rating dependen del indicador utilizado.

Los resultados son descriptivos y no permiten afirmar que la condición de edición limitada cause las diferencias observadas ni evaluar la rentabilidad de los productos.

Reflexión Metodológica: Se utilizó la IA como apoyo en el análisis y búsqueda de datos en el mismo dataset, así como una ayuda frente a problemas en la sintaxis de código o la carga de documentos, con prompts para la corrección de errores. Todo dato de la IA fue en base a la tabla proporcionada y fue posteriormente verificado por el grupo.

BibliografÍa: Se utilizó muy brevemente una ayuda del libro virtual Python for Data Analysts, Third Edition, de Wes McKinney para entender y poder solucionar problemas repetitivos en la carga del Dataset. Link: https://wesmckinney.com/book/accessing-data